

Influence des transformations d'images sur les biais inductifs des réseaux de neurones convolutionnels et des Vision Transformers

Pipeline de Transformation de Texture

Renforcement des motifs locaux et dégradation de la structure globale.



Objectifs :

- renforcer les motifs locaux
- dégrader la structure globale




Effet :

- texture renforcée
- structure globale affaiblie



Pipeline de Transformation de Texture



Aperçu de transformations d'une image

Résumé

L'objectif de ce projet est de comparer deux familles majeures de modèles de vision par ordinateur, à savoir les réseaux de neurones convolutifs (CNN) et les Vision Transformers (ViT), sur une tâche de classification d'images. Plus précisément, nous étudions ResNet-34 et DeiT-B/16 dans un cadre expérimental où la conception des données constitue le point central de l'analyse. Plutôt que de comparer naïvement deux architectures sur un dataset standard, nous construisons deux pipelines de transformation visant à mettre en évidence leurs biais inductifs respectifs. Le premier pipeline, orienté *texture*, dégrade volontairement l'organisation spatiale globale tout en renforçant les motifs locaux ; il est conçu pour favoriser les CNN, dont le mécanisme convolutif exploite naturellement les corrélations de voisinage. Le second pipeline, orienté *structure globale*, atténue les hautes fréquences et les détails fins tout en conservant les formes générales ; il vise à favoriser les Transformers, capables de modéliser des dépendances à longue portée via le mécanisme d'attention.

Les expériences sont menées sur une sous-partie du dataset Intel Image Classification provenant de Kaggle, avec quatre classes de paysages : forêt, montagne, glacier et désert. Les deux modèles sont initialisés à partir de poids pré-entraînés sur ImageNet puis entièrement ajustés (*full fine-tuning*) sur les données transformées. Le protocole expérimental repose sur l'optimiseur AdamW, un scheduler décroissant, l'early stopping, une évaluation sur plusieurs graines aléatoires, ainsi que des métriques quantitatives adaptées : accuracy et F1-score macro. Les résultats montrent une différence d'environ 8 % selon la nature du dataset, avec un avantage de ResNet sur les données orientées texture et un avantage de ViT sur les données orientées structure globale.

Au-delà de la comparaison de performance, ce travail propose une lecture interprétative des résultats en lien direct avec la théorie des architectures. Nous discutons le rôle du biais inductif local des CNN, la capacité des Transformers à capturer des interactions globales, l'effet de la petite taille du dataset, le risque de surapprentissage observé au cours de l'entraînement, ainsi que l'influence majeure du pré-entraînement sur ImageNet. Ce rapport montre ainsi que la question « quel modèle est meilleur ? » n'a de sens qu'en relation avec la nature de l'information présente dans les données et avec le protocole expérimental retenu.

Afin de garantir la reproductibilité des résultats, le code source complet du projet est mis à disposition à l'adresse suivante : [GitHub](#).

Table des matières

1	Introduction	4
2	Fondements théoriques	5
2.1	Réseaux convolutifs : structure locale et biais inductif	5
2.2	Vision Transformers : modélisation globale par attention	5
2.3	De ViT à DeiT : adaptation aux petits datasets	5
2.4	Biais inductifs et nature de l'information visuelle	6
2.5	Rôle des transformations et des augmentations	6
2.6	Lien direct avec notre démarche expérimentale	6
3	Dataset et conception expérimentale des données	7
3.1	Dataset de base	7
3.2	Idée générale de la conception des données	7
3.3	Pipeline orienté texture	7
3.3.1	Mesure de texture	8
3.4	Pipeline orienté structure globale	9
3.5	Discussion	10
4	Méthodologie expérimentale	12
4.1	Architectures comparées	12
4.2	Pré-entraînement et fine-tuning	12
4.3	Optimisation	12
4.4	Robustesse expérimentale	12
4.5	Métriques d'évaluation	12
5	Résultats	13
5.1	Résultats quantitatifs principaux	13
5.2	Analyse de sensibilité au shuffle ratio	13
5.3	Impact de la suppression aléatoire de patches	14
6	Analyse et interprétation	15
6.1	Pourquoi ResNet est meilleur sur le dataset texture ?	15
6.2	Pourquoi DeiT est meilleur sur le dataset global ?	15
6.3	Pourquoi la différence reste modérée ?	15
7	Limites de l'étude	16
7.1	Taille et diversité du dataset	16
7.2	Pré-entraînement comme facteur confondant	16
7.3	Nombre limité d'architectures	16
7.4	Absence d'analyse interne avancée	16
8	Conclusion	17

1 Introduction

La classification d’images constitue l’un des problèmes fondateurs de la vision par ordinateur moderne. Depuis l’essor du deep learning, deux grandes familles d’architectures se distinguent dans ce domaine : les réseaux de neurones convolutifs, popularisés par AlexNet [1], et plus récemment les architectures basées sur les Transformers, adaptées à la vision dans le travail fondateur de Dosovitskiy et al. [2]. Ces deux paradigmes ont en commun une grande capacité de représentation, mais ils diffèrent profondément dans leur manière d’exploiter l’information spatiale contenue dans une image.

Les CNN incorporent explicitement une hypothèse de localité : l’information visuelle est supposée pouvoir être captée à partir de motifs locaux, combinés ensuite de manière hiérarchique au fil des couches. Cette hypothèse, appelée *biais inductif*, permet aux CNN d’être particulièrement efficaces sur des volumes de données modérés, car le modèle n’a pas besoin d’apprendre à partir de rien certaines propriétés structurelles du problème. À l’inverse, les Vision Transformers reposent sur un mécanisme d’attention globale entre patchs d’image. Ils disposent d’un biais inductif plus faible, ce qui leur confère une plus grande flexibilité mais les rend en général plus dépendants du volume de données, du pré-entraînement et des stratégies de régularisation.

Dans un cadre pédagogique et scientifique, il ne suffit pas de comparer les performances brutes de deux modèles sur un benchmark générique. Il est plus instructif de concevoir des situations expérimentales où les forces et faiblesses de chaque famille apparaissent clairement. C’est l’essence même du projet : concevoir des datasets mettant en évidence les différences entre méthodes pour une même tâche. Dans cette logique, notre travail ne se limite pas à entraîner ResNet-34 et DeiT-B/16 sur un dataset d’images de paysages ; il consiste surtout à modifier ce dataset de manière contrôlée afin de créer deux datasets distincts :

- un *orienté texture*, dans lequel la structure globale est partiellement détruite tandis que les textures locales sont amplifiées.
- un *orienté structure globale*, dans lequel les détails fins sont atténués alors que les formes générales et les relations spatiales à grande échelle sont conservées.

L’hypothèse centrale est la suivante : si les CNN bénéficient d’un biais inductif local, ils devraient être avantagés lorsque la décision de classification repose principalement sur des motifs locaux répétitifs. À l’inverse, si les Transformers sont plus aptes à modéliser des dépendances globales, ils devraient être relativement avantagés lorsque la texture fine est supprimée mais que la forme globale reste discriminante. Il ne s’agit donc pas seulement de mesurer une accuracy, mais de vérifier expérimentalement une hypothèse théorique sur les mécanismes internes des architectures.

Le présent rapport s’organise comme suit. La Section ?? présente les travaux connexes sur les CNN, les Vision Transformers et les effets des stratégies d’augmentation de données et rappelle les principes mathématiques essentiels des convolutions et de l’auto-attention, puis introduit la notion de biais inductif.

La Section 3 décrit le dataset utilisé et surtout la conception des deux pipelines de transformation. La Section 4 détaille les architectures, le protocole d’entraînement et les choix de métriques. Les Sections 5 et 6 présentent les résultats puis en proposent une interprétation approfondie. Enfin, la Section 7 discute les limites de l’étude avant une conclusion générale.

2 Fondements théoriques

2.1 Réseaux convolutifs : structure locale et biais inductif

Les réseaux de neurones convolutifs (CNN), popularisés par AlexNet [1], reposent sur une hypothèse fondamentale : l'information visuelle est localement corrélée. Cette hypothèse est implémentée par une opération de convolution, qui applique un filtre spatial local sur l'image. Cette opération induit plusieurs propriétés structurantes :

- une localité forte des interactions ;
- un partage des poids sur toute l'image ;
- une construction hiérarchique des représentations.

Ces propriétés constituent ce que l'on appelle un *biais inductif*. Dans le cas des CNN, ce biais favorise naturellement l'apprentissage de motifs locaux répétitifs, tels que des textures, des contours ou des micro-structures visuelles.

Dans notre projet, nous utilisons *ResNet-34* [4], une extension de ResNet-18 avec une profondeur accrue (22 Millions de params). Ce choix apporte une valeur ajoutée importante : une meilleure capacité à agréger l'information sur des échelles plus larges tout en conservant les avantages du biais local. Empiriquement, nous avons observé que ResNet-34 accentue les différences de performance avec les Transformers, ce qui le rend plus pertinent pour notre analyse comparative.

2.2 Vision Transformers : modélisation globale par attention

Les Vision Transformers (ViT), introduits en vision par Dosovitskiy et al. [2], adoptent une approche radicalement différente. L'image est découpée en patches, chacun étant traité comme un token dans une séquence. Le cœur du modèle repose sur le mécanisme d'auto-attention :

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V. \quad (1)$$

Contrairement aux CNN, chaque patch peut interagir directement avec tous les autres. Cette propriété permet de capturer des dépendances globales sans contrainte de localité.

Cependant, ce gain en flexibilité s'accompagne d'un biais inductif plus faible. Les ViT nécessitent généralement plus de données ou un pré-entraînement fort pour atteindre des performances optimales, comme le montrent Lu et al. [3].

2.3 De ViT à DeiT : adaptation aux petits datasets

Dans notre étude, nous utilisons *DeiT-B/16* (Data-efficient Image Transformer) proposé par Touvron et al. [9]. Ce modèle constitue une évolution directe des Vision Transformers, conçue pour améliorer leurs performances dans des régimes de données plus limités.

La principale innovation de DeiT repose sur une stratégie de *distillation de connaissance*, où un modèle enseignant guide l'apprentissage du Transformer. Cette approche permet :

- d'introduire implicitement un biais inductif plus fort.
- d'améliorer la convergence sur petits datasets.

Dans notre cas, le passage de ViT classique à DeiT apporte une amélioration significative de la stabilité et accentue les écarts expérimentaux observés. Cela rend la comparaison plus lisible et plus pertinente scientifiquement.

2.4 Biais inductifs et nature de l’information visuelle

La différence fondamentale entre CNN et Transformers peut être résumée en termes de biais inductifs :

- les CNN favorisent une *lecture locale* de l’image ;
- les Transformers permettent une *intégration globale* des informations.

Cette distinction a des implications directes :

- si la classification repose sur des textures locales, les CNN devraient être avantagés ;
- si elle repose sur des relations globales, les Transformers peuvent mieux performer.

Cette hypothèse constitue le cœur de notre protocole expérimental.

2.5 Rôle des transformations et des augmentations

Les travaux récents montrent que les performances des modèles dépendent fortement des stratégies d’augmentation de données.

Dans notre approche, les transformations ne servent pas uniquement à régulariser, mais à *modifier la nature de l’information disponible*. En construisant des datasets orientés texture ou structure globale, nous utilisons les augmentations comme un outil d’analyse des modèles.

2.6 Lien direct avec notre démarche expérimentale

L’originalité de notre travail réside dans le lien explicite entre théorie et expérimentation. Plutôt que de comparer des modèles sur un dataset standard, nous construisons deux régimes perceptifs distincts :

- un régime où les *indices locaux dominent* ;
- un régime où les *indices globaux dominent*.

Cela permet de transformer une simple comparaison de performances en une expérience contrôlée sur les biais inductifs des architectures.

Ainsi, cette section fournit le cadre conceptuel nécessaire pour interpréter les résultats expérimentaux présentés dans la suite du rapport.

3 Dataset et conception expérimentale des données

3.1 Dataset de base

Nous utilisons le **Intel Image Classification Dataset** disponible sur Kaggle :

<https://www.kaggle.com/datasets/puneet6060/intel-image-classification>

Ce dataset contient des images de scènes naturelles variées. Pour garder un protocole simple et lisible, nous sélectionnons quatre classes :

- Forêt (2745 images).
- Montagne (2957 images).
- Glacier (3037 images).
- Mer (2784 images).

Le jeu de données utilisé contient environ 11523 images. Ce choix présente plusieurs intérêts :

- les classes sont visuellement distinctes mais partagent certaines régularités ;
- les scènes se prêtent bien à une analyse texture vs structure globale ;
- certaines classes possèdent des signatures texturales fortes (par exemple, le sable du désert, la granularité de la forêt, les motifs de roche ou de glace) ;
- d'autres indices discriminants relèvent davantage de la structure globale (ligne d'horizon, masses montagneuses, répartition du ciel et du sol, géométrie générale de la scène)
- le dataset reste de taille modérée, ce qui rend le problème intéressant pour comparer CNN et ViT.

Ce dataset est donc un bon support pour construire deux versions perceptivement contrastées d'un même problème de classification.

3.2 Idée générale de la conception des données

La partie centrale du projet ne consiste pas à utiliser un dataset standard tel quel, mais à le transformer pour isoler certains types d'indices visuels. Nous concevons deux pipelines :

Pipeline texture. Il vise à rendre la texture locale plus informative que la forme globale. Pour cela, on perturbe l'organisation spatiale d'ensemble tout en préservant ou en renforçant les motifs locaux.

Pipeline global. Il vise à conserver les formes générales et les relations spatiales globales tout en affaiblissant les détails fins. Il s'agit donc de lisser l'image et d'atténuer les hautes fréquences.

3.3 Pipeline orienté texture

Le pipeline orienté texture vise à favoriser les motifs locaux tout en dégradant l'organisation spatiale globale. L'objectif est de créer un régime où la décision de classification repose principalement sur des indices de voisinage.

Pour cela, plusieurs transformations sont combinées :

- **Grayscale** supprime l'information colorimétrique afin de forcer le modèle à se concentrer sur les structures d'intensité.
- **Filtrage passe-haut renforcé** ($\alpha = 35$) amplifie fortement les hautes fréquences en soustrayant une version lissée de l'image, ce qui met en évidence les détails locaux et les variations rapides d'intensité.

- **Patch shuffle partiel** (taille 8×8 , ratio 0.4) désorganise la structure globale en permutant une fraction des patches tout en conservant la cohérence locale à l'intérieur de chaque patch.
- **Normalisation locale du contraste** (LCN) centre et normalise l'image puis applique une transformation non-linéaire de type $\text{sign}(x)\sqrt{|x|}$, ce qui accentue les variations locales et augmente la saillance des textures faibles.
- **Filtrage différentiel (DoG-like)** obtenu par soustraction d'un flou gaussien ($\sigma = 5$), ce qui renforce encore les contours et les structures fines.



(a) Image originale - Texture Score = 0.141



(b) Image transformée - Texture Score = 0.622

FIGURE 1 – Comparaison entre une image originale et sa version transformée - Texture.

3.3.1 Mesure de texture

Afin de quantifier la quantité de texture présente dans une image, nous utilisons une approche basée sur l'analyse fréquentielle. Soit $I(x, y)$ l'image en niveaux de gris, définie sur une grille discrète.

L'image est transformée dans le domaine fréquentiel à l'aide de la **transformée de Fourier bidimensionnelle** :

$$\hat{I}(u, v) = \sum_x \sum_y I(x, y) e^{-2i\pi(ux+vy)}$$

où (u, v) représentent les fréquences spatiales.

L'énergie spectrale est ensuite définie comme le module au carré :

$$E(u, v) = |\hat{I}(u, v)|^2$$

Cette quantité mesure la contribution de chaque fréquence à l'image.

Une bande de fréquences intermédiaires $\mathcal{B}$ est alors isolée :

$$\mathcal{B} = \{(u, v) \mid f_{\min} \leq \sqrt{u^2 + v^2} \leq f_{\max}\}$$

Cette bande correspond aux **hautes fréquences**, associées aux variations locales rapides (textures), tout en excluant les basses fréquences liées à la structure globale de l'image.

Le score de texture est défini comme le rapport d'énergie :

$$\text{Texture Score} = \frac{\sum_{(u,v) \in \mathcal{B}} E(u,v)}{\sum_{(u,v)} E(u,v)}$$


Ainsi, une image riche en textures locales présente une proportion plus élevée d'énergie dans les hautes fréquences, ce qui se traduit par un score de texture plus élevé.

D'un point de vue signal, cela revient à appliquer implicitement un **filtre passe-haut** :

$$I_{\text{HP}} = I - G_{\sigma} * I$$

où G_{σ} est un noyau gaussien (flou), et $*$ la convolution. Cette opération supprime les composantes basses fréquences (structure globale) et met en évidence les détails locaux.

Ainsi, la cohérence globale de l'image est atténuée, tandis que les signatures texturales restent exploitables. Ce type de transformation est particulièrement adapté aux CNN, dont le biais inductif repose sur des opérateurs locaux (convolutions) capturant efficacement des motifs de petite taille.



(a) Image originale - Spectre Fréquentiel

(b) Image transformée - Spectre Fréquentiel

FIGURE 2 – Spectre fréquentiel d'une image originale et sa version transformée texture.

3.4 Pipeline orienté structure globale

Le pipeline orienté structure globale suit une logique inverse : il vise à supprimer les détails fins tout en préservant l'organisation spatiale d'ensemble.

Les transformations principales sont :


- **RandomResizedCrop** (scale $[0.6, 1.0]$) introduit une variabilité contrôlée tout en conservant une grande partie de la structure globale de la scène ;
- **Downsampling / Upsampling** ($224 \rightarrow 102 \rightarrow 224$, interpolation bilinéaire) agit comme un filtre passe-bas, supprimant les hautes fréquences et les détails fins tout en préservant les formes globales ;
- **Grayscale** réduit l'influence des distributions de couleur afin de privilégier les structures d'intensité ;
- **Flou gaussien** ($\sigma \in [1.5, 2.0]$) atténue davantage les textures locales et les variations rapides ;

- **Drop de patches aléatoire (probabilité de drop)** ($p = 0.2$, taille 8×8) : supprime localement certaines régions, ce qui limite l'exploitation de motifs locaux spécifiques ;
- **Permutation locale de patches (faible probabilité)** ($p = 0.2$, taille 8×8) : introduit une légère perturbation locale tout en conservant la cohérence globale de l'image.

Ces transformations produisent des images où les motifs locaux sont moins informatifs, mais où les relations spatiales à grande échelle sont conservées. Dans ce contexte, les modèles à attention globale comme les Transformers sont susceptibles de mieux exploiter l'information disponible.




(a) Image originale - Texture Score = 0.141




(b) Image transformée - Texture Score = 0.109

FIGURE 3 – Comparaison entre une image originale et sa version transformée structure globale



(a) Image originale - Spectre Fréquentiel



(b) Image transformée - Spectre Fréquentiel

FIGURE 4 – Spectre fréquentiel d'une image originale et sa version transformée structure globale.

3.5 Discussion

Ces deux pipelines ne suppriment pas complètement l'un ou l'autre type d'information, mais modifient leur importance relative. Ils permettent ainsi de créer deux régimes expérimentaux

complémentaires, adaptés à l'étude des biais inductifs des architectures.

4 Méthodologie expérimentale

4.1 Architectures comparées

Nous comparons deux familles d’architectures représentatives :

- **ResNet-34**, avec 22 Millions de params
- **DeiT-B/16**, avec 23 Millions de params

Le choix de DeiT comme modèle de type Transformer est volontaire. Bien qu’un modèle standard tel que ViT-B/16 ait initialement été envisagé, sa taille importante le rend peu adapté à un dataset de taille modeste. DeiT, conçu pour être plus efficace en régime de données limitées grâce à la distillation, constitue donc une alternative plus pertinente dans ce contexte.

Cependant, ce choix ne modifie pas la nature fondamentale du modèle : DeiT repose sur les mêmes mécanismes d’attention globale que les Vision Transformers. Ainsi, son utilisation permet de mettre en évidence que les propriétés intrinsèques des architectures Transformers, notamment leur capacité à exploiter des dépendances globales, persistent même lorsqu’elles sont optimisées pour des jeux de données plus restreints.

4.2 Pré-entraînement et fine-tuning

Les deux modèles sont initialisés avec des poids pré-entraînés sur ImageNet puis entièrement ajustés sur notre dataset (**fine-tuning complet sur tous les poids du modèle**).

Nous avons observé qu’un entraînement limité à la tête de classification conduisait à de mauvaises performances. Cela s’explique par la forte modification des distributions d’entrée induite par nos pipelines. Il est donc nécessaire d’adapter l’ensemble des représentations internes.

4.3 Optimisation

L’entraînement repose sur :

- l’optimiseur **AdamW**, adapté aux architectures modernes.
- un **scheduler décroissant** du taux d’apprentissage lorsque les performances stagnent.
- un **early stopping** pour limiter le surapprentissage.

Ces choix permettent de stabiliser l’apprentissage tout en s’adaptant à la taille limitée du dataset.

4.4 Robustesse expérimentale

Afin de garantir la fiabilité des résultats, chaque expérience est répétée avec plusieurs graines aléatoires. Cela permet d’obtenir une estimation plus robuste des performances.

4.5 Métriques d’évaluation

Nous utilisons deux métriques complémentaires :

- **Accuracy**, qui mesure la proportion de prédictions correctes.
- **F1-score**, qui évalue la capacité du modèle à faire de bonnes prédictions en suffisamment grand nombre

Le F1-score est particulièrement pertinent dans notre contexte, car il permet de vérifier que les performances ne sont pas dominées par une seule classe.

5 Résultats

5.1 Résultats quantitatifs principaux

Le Tableau 1 présente la structure attendue pour les performances moyennes sur les deux régimes de données. Les valeurs numériques finales seront à renseigner à partir des expériences réalisées. D'après les observations obtenues, on s'attend à un écart d'environ 8% entre les deux architectures selon le type de dataset.

TABLE 1 – Comparaison des performances sur les différents datasets.

Modèle	Dataset de base		Dataset texture		Dataset structure globale	
	Accuracy	F1 macro	Accuracy	F1 macro	Accuracy	F1 macro
ResNet-34	0.92	0.91	0.87 ± 0.003	0.87 ± 0.002	0.76 ± 0.001	0.77 ± 0.005
DeiT-B/16	0.95	0.95	0.81 ± 0.001	0.82 ± 0.003	0.85 ± 0.005	0.85 ± 0.005

5.2 Analyse de sensibilité au shuffle ratio

Afin d'étudier l'impact de la désorganisation de la structure globale, nous faisons varier le paramètre de *shuffle ratio* dans l'opération de *patch shuffle partiel*. Ce paramètre contrôle la proportion de patchs permutés dans l'image.

La Figure 5 présente l'évolution des performances en fonction de ce paramètre pour ResNet-34 et DeiT-B/16.




FIGURE 5 – Impact du shuffle ratio sur les performances des modèles.

On observe que l'augmentation du shuffle ratio entraîne une dégradation des performances pour les deux modèles. Cependant, cette dégradation est plus marquée pour DeiT-B/16, ce qui suggère une plus grande sensibilité à la perte de structure globale.

À l'inverse, ResNet-34 reste relativement stable pour des valeurs modérées du shuffle ratio, ce qui confirme sa capacité à exploiter des motifs locaux même lorsque l'organisation globale est partiellement altérée.

5.3 Impact de la suppression aléatoire de patches

Afin d'évaluer la robustesse des modèles face à une perte d'information locale, nous introduisons une transformation de type *random multi-patch drop*, qui consiste à supprimer aléatoirement une proportion de patches de l'image en les remplaçant par des valeurs nulles.

La Figure 6 présente l'évolution des performances en fonction de la probabilité de suppression.




FIGURE 6 – Impact de la probabilité de suppression de patches sur les performances des modèles.

On observe que l'augmentation de la probabilité de suppression entraîne une dégradation des performances pour les deux modèles. Toutefois, cette dégradation est significativement plus marquée pour ResNet-34, dont les performances chutent rapidement lorsque la continuité spatiale est fortement altérée.

À l'inverse, DeiT-B/16 conserve des performances relativement élevées, même pour des niveaux importants de suppression. Ce comportement suggère que les modèles basés sur l'attention sont capables de redistribuer l'importance sur les patches restants et de compenser partiellement la perte d'information locale.

Ces résultats confirment que la suppression d'information locale pénalise davantage les architectures convolutives, tandis que les architectures basées sur l'attention montrent une meilleure robustesse face à des données incomplètes.

6 Analyse et interprétation

6.1 Pourquoi ResNet est meilleur sur le dataset texture ?

Les performances supérieures de ResNet-34 sur le dataset texture s'expliquent directement par son biais inductif local. Les transformations appliquées (filtrage passe-haut, patch shuffle, normalisation locale) détruisent en grande partie la structure globale tout en préservant les motifs locaux.

Les convolutions exploitent précisément ce type d'information : elles détectent des structures de voisinage (textures, gradients, micro-patterns) qui restent discriminantes même lorsque l'organisation globale est altérée. Cette robustesse aux perturbations spatiales globales confère un avantage aux CNN dans ce contexte.

6.2 Pourquoi DeiT est meilleur sur le dataset global ?

Sur le dataset global, les transformations atténuent les hautes fréquences et réduisent l'information locale, ce qui rend la classification dépendante de la structure globale de la scène.

DeiT, basé sur un mécanisme d'attention, permet des interactions directes entre toutes les régions de l'image. Cela facilite l'agrégation d'informations à grande échelle, comme la disposition globale des éléments (horizon, masses, organisation spatiale).

Ainsi, lorsque les indices discriminants sont distribués globalement, DeiT présente un avantage relatif sur ResNet.

6.3 Pourquoi la différence reste modérée ?

Malgré ces tendances, l'écart observé reste limité (environ 7 à 10 %). Plusieurs facteurs expliquent cela :

- les deux modèles sont pré-entraînés sur ImageNet et disposent déjà de représentations visuelles riches ;
- les transformations ne produisent pas des datasets parfaitement spécialisés (le dataset texture conserve une structure résiduelle, et inversement) ;
- ResNet peut agréger de l'information à plus grande échelle via la profondeur ;
- DeiT reçoit des patchs contenant encore de l'information locale.

Les résultats reflètent donc une différence de *préférence inductive* plutôt qu'une supériorité absolue d'un modèle sur l'autre.

7 Limites de l'étude

7.1 Taille et diversité du dataset

Le dataset utilisé reste relativement limité pour des architectures modernes. Une évaluation sur un ensemble plus large et plus diversifié permettrait de renforcer la robustesse des conclusions.

7.2 Pré-entraînement comme facteur confondant

L'utilisation de poids pré-entraînés sur ImageNet améliore les performances mais atténue les différences intrinsèques entre architectures, rendant la comparaison moins "pure".

7.3 Nombre limité d'architectures

L'étude se limite à ResNet-34 et DeiT-B/16. L'inclusion d'autres architectures ou variantes permettrait de généraliser davantage les résultats.

7.4 Absence d'analyse interne avancée

L'interprétation repose principalement sur les performances. Des analyses complémentaires (visualisation des activations, étude d'ablation) permettraient d'approfondir la compréhension des mécanismes en jeu.

8 Conclusion

Ce travail propose une comparaison entre ResNet-34 et DeiT-B/16 en mettant l'accent sur la conception des données. En construisant deux pipelines contrastés, orientés respectivement vers la texture et la structure globale, nous avons mis en évidence l'influence du biais inductif des architectures.

Les résultats montrent que ResNet-34 est plus performant lorsque l'information discriminante est locale, tandis que DeiT-B/16 présente un avantage lorsque la structure globale domine. Cet écart reste modéré, en raison notamment du pré-entraînement et de la nature non parfaitement séparée des datasets.

Au-delà des performances, ce travail souligne un point essentiel : la pertinence d'un modèle dépend de l'adéquation entre son biais inductif et la structure des données. La conception expérimentale joue ainsi un rôle central dans l'interprétation des résultats.

Plusieurs extensions sont envisageables, notamment, l'étude des représentations internes, les transformations pendant l'entraînement des modèles (AugMix ...) et l'évaluation sur des architectures et datasets plus larges.

Références

- [1] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. ImageNet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems*, 2012.
- [2] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words : Transformers for image recognition at scale. *arXiv preprint arXiv :2010.11929*, 2020.
- [3] Zhiying Lu, Hongtao Xie, Chuanbin Liu, and Yongdong Zhang. Bridging the gap between vision transformers and convolutional neural networks on small datasets. In *Advances in Neural Information Processing Systems*, 2022.
- [4] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016.
- [5] Sangdoo Yun, Dongyoon Han, Seong Joon Oh, Sanghyuk Chun, Junsuk Choe, and Youngjoon Yoo. CutMix : Regularization strategy to train strong classifiers with localizable features. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2019.
- [6] Dan Hendrycks, Norman Mu, Ekin D. Cubuk, Barret Zoph, Justin Gilmer, and Balaji Lakshminarayanan. AugMix : A simple data processing method to improve robustness and uncertainty. In *International Conference on Learning Representations*, 2020.
- [7] Robert Geirhos, Patricia Rubisch, Claudio Michaelis, Matthias Bethge, Felix A. Wichmann, and Wieland Brendel. ImageNet-trained CNNs are biased towards texture; increasing shape bias improves accuracy and robustness. In *International Conference on Learning Representations*, 2019.
- [8] Maithra Raghu, Drew Jaegle, Matthew D. Zeiler, Jonathan B. Tenenbaum, Neil Houlsby, and Jascha Sohl-Dickstein. Do Vision Transformers see like convolutional neural networks ? In *Advances in Neural Information Processing Systems*, 2021.
- [9] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. In *International Conference on Machine Learning*, 2021.